

Henrique Kioshi Yamauchi
Renato Jorge Alpalhão

Modelagem Baseada em Agentes (ABM) para Simular a Disseminação da Dengue

São Paulo - Brasil

2025

Lista de ilustrações

Figura 1 – Exemplo de simulação usando ABM para análise de propagação de doença.	6
Figura 2 – Exemplo do Mosquito.	10
Figura 3 – Diagrama esquemático do modelo SI.	11
Figura 4 – Diagrama esquemático do modelo SIS.	11
Figura 5 – Diagrama esquemático do modelo SIR.	12
Figura 6 – Exemplo de modelo no Mesa.	13
Figura 7 – Estrutura geral de um modelo desenvolvido com o framework Mesa.	15
Figura 8 – Estrutura geral de um modelo desenvolvido com o framework Mesa.	19
Figura 9 – Comparação entre séries reais e simuladas ao longo de quinze dias.	25

Listas de abreviaturas e siglas

ABM	Modelagem Baseada em Agentes (<i>Agent-Based Modeling</i>)
GIS	Sistema de Informação Geográfica (<i>Geographic Information System</i>)
GAML	Linguagem de Modelagem do GAMA (<i>GAMA Modeling Language</i>)
SIR	Modelo Suscetível-Infectado-Recuperado
SIS	Modelo Suscetível-Infectado-Suscetível
SI	Modelo Suscetível-Infectado
DENV	Vírus da Dengue (<i>Dengue Virus</i>)
INMET	Instituto Nacional de Meteorologia
IBGE	Instituto Brasileiro de Geografia e Estatística
CSV	Valores Separados por Vírgula (<i>Comma-Separated Values</i>)
QGIS	Sistema de Informação Geográfica de Código Aberto
WHO	Organização Mundial da Saúde (<i>World Health Organization</i>)
UBC	Unidade Básica de Compartimentação
OD	Origem e Destino
TCC	Trabalho de Conclusão de Curso

Sumário

1	INTRODUÇÃO	5
1.1	Contextualização	5
1.2	Justificativa	6
1.3	Objetivo Geral	7
1.4	Objetivos Específicos	7
2	REVISÃO BIBLIOGRÁFICA	8
2.1	Modelos Baseados em Agentes (ABM)	8
2.1.1	História dos Modelos Baseados em Agentes	8
2.1.2	Agentes	8
2.1.3	Ambiente	9
2.1.4	Interações e Relações	9
2.1.5	História dos Modelos Baseados em Agentes	9
2.1.6	Modelos Tradicionais em Comparação com ABM	10
2.2	Arboviroses e Dengue	10
2.2.1	Uso da Dengue como Modelo	11
2.3	Modelos Epidemiológicos Tradicionais	11
2.3.1	Descrição do Modelo: Agentes, Variáveis e Ambiente	12
2.4	O Framework Mesa	12
2.4.1	História do Mesa	13
2.4.2	Estrutura de Modelagem no Mesa	14
2.4.3	Fundamentos e Sintaxe do Mesa	14
2.4.4	Estrutura de Agentes e Ambientes	15
2.4.5	Importação e Uso de Dados Reais	15
2.4.6	Importação e Uso de Dados Reais	16
2.4.7	Exportação de Resultados e Integração com Outras Ferramentas	16
2.4.8	Exportação e Integração com Outras Ferramentas	16
2.5	GIS e Dados Externos	17
2.5.1	GIS	17
2.5.2	Shapefiles e Dados Geoespaciais	18
2.5.2.1	Ferramentas de apoio à modelagem espacial	20
2.6	Trabalhos Relacionados	20
2.6.1	Modelagem da Dengue com Base em Agentes e Mobilidade Urbana	20
2.6.2	Towards Virtual Epidemiology: An Agent-Based Approach to the Modeling of H5N1	20
2.6.3	Interventions to control nosocomial transmission of SARS-CoV-2: a modelling study	21
3	METODOLOGIA	22
3.1	Arquitetura Geral do Modelo	22
3.2	Modelagem Baseada em Agentes	22
3.2.1	Agente Ambiente	22
3.2.2	Agente Mosquito	23
3.2.3	Agente Humano	23

3.3	Integração de Dados Climáticos e Estruturais	23
4	RESULTADOS E VALIDAÇÃO DO MODELO	24
4.1	Comparação entre dados simulados e reais	24
4.2	Representação gráfica comparativa	25
4.3	Efeitos climáticos na dinâmica da transmissão	25
4.4	Coerência e desempenho do modelo híbrido	25
4.5	Limitações identificadas	26
5	CONCLUSÃO	27
6	TRABALHOS FUTUROS	28
	REFERÊNCIAS	29

1 Introdução

1.1 Contextualização

Os Modelos Baseados em Agentes (ABMs) são ferramentas computacionais para a análise de sistemas complexos, capazes de simular a interação de indivíduos ou agentes em um ambiente definido. Cada agente possui características próprias e toma decisões de forma autônoma, influenciando e sendo influenciado pelo contexto ao seu redor. Essa abordagem permite observar padrões emergentes que surgem da interação entre agentes e ambiente, oferecendo insights que seriam difíceis de obter por meio de modelos tradicionais.

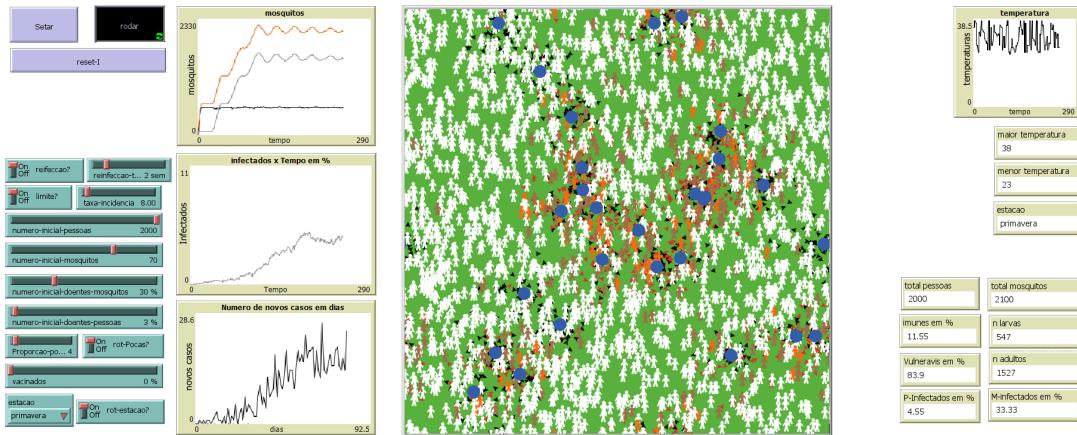
No estudo da disseminação de doenças transmitidas por vetores, como a dengue, os ABMs possibilitam representar detalhadamente a população humana, o comportamento dos vetores e as interações entre eles, incorporando fatores ambientais, sociais e espaciais. Diferentemente de modelos matemáticos agregados, que tratam a população de forma homogênea, os ABMs permitem incluir heterogeneidade nos agentes, mobilidade urbana, hábitos e decisões individuais.

Além disso, os ABMs permitem a experimentação com cenários hipotéticos e políticas de intervenção, como campanhas de conscientização, aplicação de medidas de controle ou alterações no ambiente urbano. Essa flexibilidade torna-os ferramentas valiosas para pesquisadores e gestores públicos na avaliação de estratégias de prevenção e mitigação.

Com as mudanças climáticas e a capacidade de adaptação dos vetores a novos ambientes têm ampliado significativamente a disseminação de arboviroses em todo o mundo. Arboviroses são doenças virais transmitidas por artrópodes, como mosquitos e carrapatos, que afetam milhões de pessoas anualmente, sobretudo em regiões tropicais e subtropicais. No Brasil, uma das arboviroses mais relevantes é a dengue, que continua representando um grave problema de saúde pública. Esses modelos oferecem uma visão mais realista e dinâmica da propagação da doença, permitindo a simulação de cenários hipotéticos e o teste de intervenções como campanhas de conscientização, uso de inseticidas, controle de focos do mosquito e estratégias de mobilização social. Isso os torna ferramentas valiosas no apoio à formulação de políticas públicas de saúde.

Assim, a utilização de ABMs na análise da disseminação da dengue representa uma ferramenta, capaz de oferecer subsídios práticos e teóricos para estratégias mais eficazes de controle e prevenção da doença.

Figura 1 – Exemplo de simulação usando ABM para análise de propagação de doença.



Fonte: Figura produzida pelo autor

1.2 Justificativa

A dengue representa um grave problema de saúde pública no Brasil, afetando milhões de pessoas e sobrecarregando os sistemas de vigilância e atendimento. Mesmo com políticas de controle vetorial e campanhas de conscientização, a doença continua apresentando altos índices de incidência e letalidade em diversas regiões do país. Diante desse cenário, torna-se urgente o desenvolvimento de ferramentas que permitam compreender com maior precisão os fatores que influenciam sua disseminação e que subsidiem estratégias de intervenção mais eficazes.

Nesse contexto, os Modelos Baseados em Agentes (ABMs) surgem como uma abordagem promissora por sua capacidade de simular, com alto nível de detalhamento, as interações entre indivíduos, vetores e o ambiente. Ao contrário de modelos matemáticos tradicionais, os ABMs permitem representar explicitamente a heterogeneidade dos agentes e suas decisões, o que é especialmente útil no estudo de doenças complexas como a dengue.

Este trabalho justifica-se pela utilização de dados reais geográficos, sociais e meteorológicos para alimentar e calibrar o modelo. Essa integração confere ao ABM um grau elevado de realismo, possibilitando simulações mais próximas da realidade observada em regiões específicas. Com dados geográficos, é possível mapear áreas de risco com maior precisão; dados sociais permitem considerar comportamentos populacionais que afetam a transmissão; e dados meteorológicos, como temperatura e precipitação, influenciam diretamente a dinâmica do vetor *Aedes aegypti*.

Ao reunir essas fontes de informação em um único modelo computacional, pretende-se criar uma ferramenta para pesquisadores, gestores públicos e autoridades de saúde, capaz de prever cenários, testar intervenções e contribuir efetivamente para o controle da dengue. Dessa forma, o presente trabalho busca não apenas um avanço metodológico, mas também uma aplicação prática com potencial de impacto social significativo.

1.3 Objetivo Geral

Desenvolver um modelo computacional utilizando a técnica de Modelagem Baseada em Agentes (ABM) para simular a dinâmica de sistemas urbanos complexos, integrando dados geográficos, meteorológicos e sociais. O modelo será implementado em Python, aproveitando bibliotecas para simulação, visualização e análise de dados, permitindo observar padrões emergentes e testar diferentes cenários de intervenção de forma virtual. A proposta é criar uma ferramenta flexível, escalável e reproduzível, capaz de gerar insights quantitativos sobre interações entre agentes e ambiente, facilitando experimentação, avaliação de políticas e suporte à tomada de decisão em contextos urbanos.

1.4 Objetivos Específicos

- Coletar e integrar dados reais geográficos, sociais e meteorológicos para alimentar e calibrar o ABM;
- Modelar agentes humanos e suas interações com o ambiente urbano, considerando mobilidade, comportamento e decisões individuais;
- Simular diferentes cenários de intervenção e avaliar seus impactos sobre a propagação da doença;
- Identificar padrões emergentes, áreas de maior risco e condições que favorecem a disseminação;
- Validar o modelo comparando os resultados simulados com dados históricos e observações empíricas.

2 REVISÃO BIBLIOGRÁFICA

2.1 Modelos Baseados em Agentes (ABM)

Modelos Baseados em Agentes (ABM, do inglês *Agent-Based Models*) constituem uma metodologia computacional que busca representar e simular sistemas complexos a partir da interação de múltiplos agentes autônomos. Conforme destacado por Macal e North ([MACAL; NORTH, 2010](#)), essa abordagem possibilita o estudo de como comportamentos coletivos emergem das decisões e ações locais dos agentes, dispensando a necessidade de uma coordenação centralizada. Dessa forma, os ABMs oferecem uma visão detalhada e bottom-up dos sistemas, onde as propriedades globais resultam da dinâmica entre as partes constituintes, e não de uma visão agregada simplificada.

O funcionamento de um ABM se baseia em três pilares: agentes, ambiente e interações. Os agentes possuem regras próprias de comportamento e podem tomar decisões, adaptar-se ou aprender. O ambiente fornece o espaço físico ou virtual onde os agentes atuam. As interações entre agentes e entre agentes e o ambiente resultam em dinâmicas coletivas que dificilmente poderiam ser previstas apenas a partir das regras individuais.

2.1.1 História dos Modelos Baseados em Agentes

Os modelos baseados em agentes surgiram a partir das décadas de 1970 e 1980, impulsionados pelo avanço da computação e pela necessidade de estudar sistemas complexos. Trabalhos pioneiros em inteligência artificial distribuída, simulações sociais e biológicas contribuíram para consolidar a área, que ganhou maior popularidade nos anos 1990 com o crescimento do poder computacional.

2.1.2 Agentes

No coração dos ABMs estão os agentes, definidos como entidades autônomas que possuem capacidade de percepção, tomada de decisão e ação dentro do ambiente em que se encontram. Cada agente é caracterizado por um conjunto de atributos que representam seu estado interno, propriedades individuais ou objetivos específicos. Tais atributos podem incluir informações como idade, localização, recursos disponíveis, estado emocional ou qualquer outra variável relevante ao sistema modelado.

Além disso, os agentes são dotados de regras de comportamento — também chamadas de heurísticas ou algoritmos — que determinam como eles reagem a estímulos do ambiente e às interações com outros agentes. Essas regras podem variar desde mecanismos simples e determinísticos até processos complexos que envolvem aprendizado, adaptação e até evolução ao longo do tempo. Segundo Macal e North ([MACAL; NORTH, 2010](#)), a autonomia dos agentes é fundamental para a captura da diversidade e heterogeneidade presentes em sistemas reais, permitindo que cada agente tome decisões localizadas e independentes, conforme seu próprio contexto e objetivos.

Outro aspecto importante é que os agentes podem possuir diferentes níveis de racionalidade e informação. Em algumas situações, agentes podem operar com conhecimento

completo sobre o sistema; em outras, apenas com informações parciais ou mesmo incorretas, o que acrescenta realismo e complexidade ao modelo. Essa diversidade na capacidade de decisão torna os ABMs especialmente poderosos para investigar sistemas sociais, econômicos e naturais, onde a heterogeneidade é a regra, não a exceção.

2.1.3 Ambiente

O ambiente é o espaço onde os agentes estão inseridos e onde suas ações acontecem. Ele pode ser representado de várias maneiras, dependendo do domínio do problema: grades bidimensionais, redes de conexões, espaços contínuos ou até mapas geográficos reais. O ambiente não é apenas um palco passivo, mas um componente ativo do sistema, fornecendo recursos, impondo restrições e influenciando diretamente o comportamento dos agentes.

Por exemplo, um ambiente pode conter variáveis como disponibilidade de alimentos, obstáculos físicos, níveis de poluição, ou mesmo regras culturais que modificam as interações possíveis. Macal e North ([MACAL; NORTH, 2010](#)) enfatizam que a modelagem detalhada do ambiente é crucial para possibilitar interações realistas e contextualizadas, onde agentes percebem e respondem às condições locais de forma dinâmica.

Além disso, o ambiente pode evoluir independentemente das ações dos agentes ou em resposta a elas, criando um sistema coevolutivo. Essa dinâmica entre agentes e ambiente amplia significativamente a complexidade do modelo e permite estudar fenômenos como retroalimentação, adaptação ambiental e resiliência dos sistemas.

2.1.4 Interações e Relações

As interações entre agentes, e entre agentes e ambiente, são o mecanismo fundamental que gera a dinâmica e os padrões observados nos ABMs. Essas interações são formalizadas por regras explícitas que definem como, quando e com quem os agentes se comunicam, competem, cooperam ou influenciam uns aos outros. Macal e North ([MACAL; NORTH, 2010](#)) ressaltam que a riqueza dessas relações possibilita a emergência de comportamentos coletivos complexos que não podem ser facilmente previstos a partir das regras individuais isoladas.

As interações podem ser diretas — como troca de informações, negociação ou disputa por recursos — ou indiretas, mediadas pelo ambiente, como quando agentes modificam o ambiente e afetam outros agentes posteriormente. Essas relações podem variar em intensidade, frequência e escopo, refletindo diferentes níveis de proximidade ou influência social, física ou funcional.

Além disso, a temporalidade é um aspecto essencial: as interações ocorrem ao longo de passos discretos da simulação, e o resultado de cada ciclo impacta o estado dos agentes e do ambiente para os ciclos subsequentes. Essa dinâmica temporal permite analisar a evolução dos sistemas e observar fenômenos como a formação de agrupamentos, ciclos de feedback, propagação de informações e outras formas de organização emergente.

2.1.5 História dos Modelos Baseados em Agentes

Os ABM surgiram entre as décadas de 1970 e 1980, em um contexto de crescente interesse em inteligência artificial distribuída, simulações sociais e biológicas. Pesquisadores buscavam compreender como sistemas descentralizados produziam fenômenos emergentes.

A consolidação da área ocorreu nos anos 1990, impulsionada pelo avanço computacional e pela necessidade de estudar problemas complexos em ciências sociais, economia, biologia e epidemiologia.

2.1.6 Modelos Tradicionais em Comparaçāo com ABM

Modelos matemáticos tradicionais, como equações diferenciais, descrevem o comportamento médio de sistemas complexos, mas geralmente ignoram a heterogeneidade dos indivíduos. Já os ABM permitem modelar diferenças entre agentes, considerar múltiplos níveis de interação e incorporar variáveis contextuais, tornando-se uma ferramenta poderosa para compreender sistemas dinâmicos e não lineares.

2.2 Arboviroses e Dengue

As arboviroses são doenças causadas por vírus transmitidos por artrópodes hematófagos, como mosquitos e carrapatos. Entre os principais agentes transmissores, destacam-se os mosquitos dos gêneros *Aedes*, *Culex* e *Anopheles*. Essas doenças representam um desafio crescente para a saúde pública, especialmente em países tropicais e subtropicais, onde as condições ambientais favorecem a reprodução e a disseminação dos vetores.

Uma das arboviroses mais conhecidas é a dengue, causada pelo vírus *Dengue virus* (DENV). Este vírus pertence à família *Flaviviridae* e ao gênero *Flavivirus*. Existem quatro sorotipos principais: DENV-1, DENV-2, DENV-3 e DENV-4, todos transmitidos pelo mosquito *Aedes aegypti* ([World Health Organization, 2023](#)). Segundo a Organização

Figura 2 – Exemplo do Mosquito.



Fonte: ([Wikipédia, 2024](#))

Mundial da Saúde (WHO), aproximadamente 80% dos casos de dengue ocorrem no continente americano, embora a doença também esteja presente em regiões tropicais da Ásia, África e Oceania. Atualmente, há registros da doença em cerca de 80 países e territórios, abrangendo cinco regiões da OMS: África, Américas, Sudeste Asiático, Pacífico Ocidental e Mediterrâneo Oriental ([World Health Organization, 2023](#)).

2.2.1 Uso da Dengue como Modelo

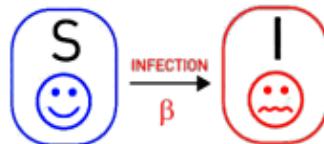
A escolha da dengue como modelo de estudo justifica-se pela sua ampla disseminação, relevância epidemiológica e pela necessidade de estratégias eficazes de controle. Além disso, a dinâmica de transmissão envolve múltiplos fatores, como comportamento humano, condições ambientais e interações entre vetor e hospedeiro, o que torna a dengue um caso ideal para aplicação de ABM.

2.3 Modelos Epidemiológicos Tradicionais

Modelos epidemiológicos são ferramentas matemáticas fundamentais no estudo da dinâmica de doenças infecciosas. Eles permitem descrever, analisar e prever o comportamento de epidemias a partir da evolução de diferentes estados de saúde na população ao longo do tempo. Esses modelos são baseados em compartimentos que representam os possíveis estados de um indivíduo em relação à doença, como suscetível, infectado ou recuperado. Entre os modelos clássicos mais utilizados destacam-se o SI, SIS e SIR.

O modelo SI (Suscetível-Infectado) é o mais simples, assumindo que uma vez infectado, o indivíduo permanece infectado para sempre, sem recuperação. Ele é útil para representar doenças crônicas ou sem cura.(COSTA, 2025)

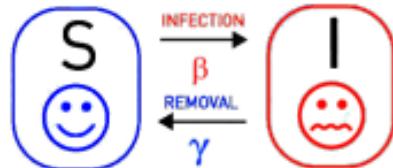
Figura 3 – Diagrama esquemático do modelo SI.



Fonte: (COSTA, 2025)

O modelo SIS (Suscetível-Infectado-Suscetível) introduz a possibilidade de recuperação, mas sem imunidade duradoura: os indivíduos recuperados retornam ao estado suscetível. Este modelo é adequado para doenças como a gripe comum.(COSTA, 2025)

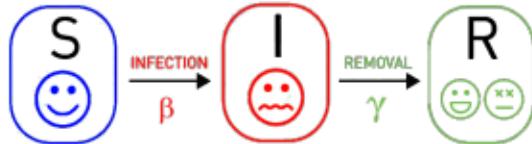
Figura 4 – Diagrama esquemático do modelo SIS.



Fonte: (COSTA, 2025)

O modelo SIR (Suscetível-Infectado-Recuperado) considera que os indivíduos recuperados adquirem imunidade permanente, deixando de participar da cadeia de transmissão. É aplicável a doenças como o sarampo.(COSTA, 2025) Apesar de sua utilidade, esses modelos apresentam limitações importantes. A principal delas é a suposição de

Figura 5 – Diagrama esquemático do modelo SIR.



Fonte: ([COSTA, 2025](#))

homogeneidade na população, ou seja, todos os indivíduos têm a mesma probabilidade de contato e transmissão. Isso ignora a complexidade das interações sociais reais, que variam segundo fatores como idade, mobilidade, hábitos e local de residência. Além disso, esses modelos geralmente não incorporam explicitamente o espaço geográfico nem as variações ambientais.

Em contraste, os Modelos Baseados em Agentes (ABMs) oferecem uma abordagem mais flexível e realista, ao representar indivíduos como entidades autônomas que interagem entre si e com o ambiente segundo regras definidas. Essa capacidade de representar heterogeneidade, comportamentos adaptativos e espacialização das interações faz dos ABMs uma alternativa promissora para simulações epidemiológicas complexas, como as associadas à disseminação da dengue em contextos urbanos.

2.3.1 Descrição do Modelo: Agentes, Variáveis e Ambiente

No contexto da dengue, os agentes podem incluir mosquitos, pessoas e focos de água parada. As variáveis englobam fatores biológicos, climáticos e sociais, como temperatura, densidade populacional e hábitos de prevenção. O ambiente corresponde ao espaço urbano ou rural onde essas interações ocorrem. A combinação desses elementos permite construir simulações realistas da dinâmica de transmissão.

2.4 O Framework Mesa

O *Mesa* é um framework open-source voltado à construção, execução e análise de modelos baseados em agentes utilizando a linguagem Python ([HOEVEN et al., 2025](#)). Desenvolvido com foco na flexibilidade e na reproduzibilidade científica, o Mesa possibilita a criação de simulações complexas de forma modular e extensível, integrando-se de maneira natural com o ecossistema de ciência de dados em Python, que inclui bibliotecas como *NumPy*, *Pandas*, *Matplotlib* e *SciPy*.

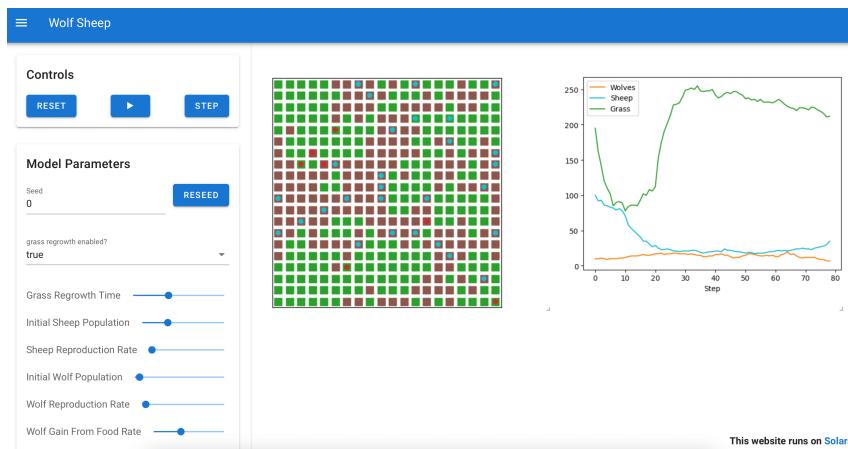
A arquitetura do Mesa é composta por quatro elementos principais que estruturam o desenvolvimento de um modelo baseado em agentes:

- **Model:** representa o ambiente global da simulação. É responsável por inicializar os agentes, definir parâmetros e variáveis globais, além de gerenciar o avanço temporal do sistema.
- **Agent:** define as entidades autônomas que interagem entre si e com o ambiente. Cada agente possui atributos próprios e métodos que determinam seu comportamento ao longo da simulação.

- **Scheduler:** controla a ordem de execução dos agentes a cada passo da simulação, podendo seguir diferentes estratégias, como atualização aleatória ou sequencial.
- **DataCollector:** coleta e armazena informações durante a simulação, permitindo a análise quantitativa dos resultados e a exportação para ferramentas de análise estatística e visualização.

Além desses componentes centrais, o Mesa disponibiliza um módulo de visualização interativa via navegador, desenvolvido com HTML e JavaScript, que possibilita acompanhar a evolução do modelo em tempo real. Essa interface facilita o processo de validação e análise, permitindo observar comportamentos emergentes à medida que a simulação progride.

Figura 6 – Exemplo de modelo no Mesa.



Fonte: ([HOEVEN et al., 2025](#))

De acordo com Fischer e Nijkamp (1992), a principal distinção dos GIS frente a sistemas de mapeamento tradicionais é sua capacidade de realizar análises espaciais complexas, indo além da visualização. No entanto, os autores também observam que, apesar da maturidade tecnológica alcançada, muitos sistemas ainda carecem de funcionalidades analíticas avançadas, sendo essencial o desenvolvimento de GIS inteligentes integrados a modelos espaciais e ferramentas estatísticas. (FISCHER; NIJKAMP, 1992). Neste trabalho, o GIS desempenha papel fundamental na construção de um ambiente geográfico que serve de base para o modelo baseado em agentes. Através de shapefiles contendo os limites dos bairros e dados populacionais do município em estudo, é possível representar o espaço urbano de forma fidedigna. Isso permite que os agentes — representando indivíduos da população — interajam com o ambiente levando em consideração fatores geográficos reais, como densidade populacional, presença de criadouros e acessibilidade urbana, contribuindo para uma simulação mais realista e robusta da disseminação da dengue.

2.4.1 História do Mesa

O Mesa é um *framework* de código aberto em Python para modelagem baseada em agentes (ABM), criado para permitir que pesquisadores desenvolvam, analisem e visualizem simulações baseadas em agentes de forma acessível e integrada ao ecossistema científico do Python.

Sua primeira versão foi lançada em 2014, com publicação acadêmica inicial em Masad et al. (2015). Naquele momento, o Mesa surgiu como uma resposta às limitações de ferramentas consolidadas como NetLogo (limitado a modelos pequenos) e MASON (baseado em Java e complexo para não programadores). Além disso, nenhuma das duas oferecia suporte nativo para execução de modelos via HTTP ou integração com as bibliotecas científicas do Python. Em 2025, o Mesa chegou à sua versão 3.1.5, marcando um amadurecimento do *framework* com funcionalidades estabilizadas, melhorias na gestão de agentes, coleta de dados, visualização e suporte a experimentação. Essa evolução tornou o Mesa uma ferramenta versátil e robusta, utilizada em mais de 500 artigos científicos e por mais de 800 autores, aplicada em áreas como economia, sociologia, ecologia, epidemiologia, logística e energia.

Ao longo dos anos, o Mesa também expandiu seu ecossistema com extensões como:

- Mesa-Geo: para modelagem geoespacial
- Mesa-Frames: para simulações de alto desempenho

Consolidando-se como uma plataforma completa e comunitária para modelagem baseada em agentes em Python.

2.4.2 Estrutura de Modelagem no Mesa

A modelagem no *Mesa* é organizada em torno de uma estrutura modular que define claramente a separação entre os componentes fundamentais de um modelo baseado em agentes. Cada simulação é composta por quatro elementos principais: o **Model**, que representa o ambiente e o controle global da simulação; o **Agent**, que define as entidades autônomas; o **DataCollector**, responsável pela coleta de resultados; e os módulos de visualização, que permitem o acompanhamento interativo dos experimentos (??).

Essa estrutura fornece ao modelador uma base flexível para desenvolver simulações escaláveis e reprodutíveis. Além disso, o Mesa é totalmente compatível com o ecossistema científico em Python, permitindo a integração com bibliotecas como *NumPy*, *Pandas*, *Matplotlib* e *NetworkX*. Essa compatibilidade possibilita tanto a análise estatística avançada quanto a criação de visualizações e a exportação de resultados para outras plataformas.

2.4.3 Fundamentos e Sintaxe do Mesa

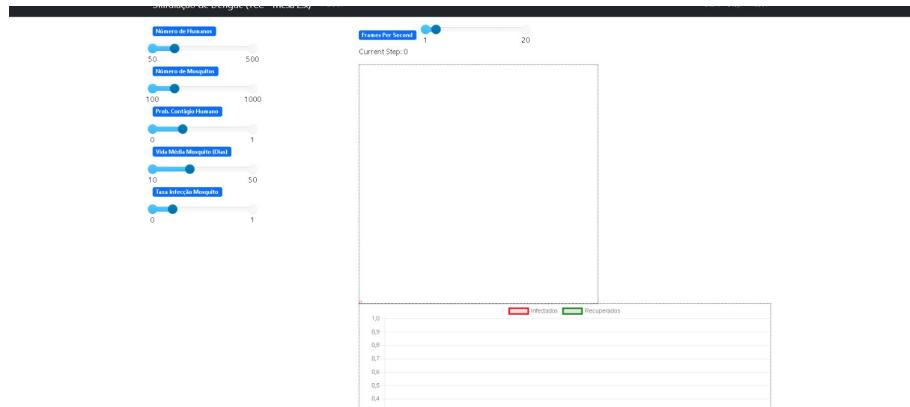
No *Mesa*, cada modelo é definido como uma classe que herda de `mesa.Model`. Dentro dessa classe, o pesquisador especifica os agentes, o espaço de simulação e as regras de atualização temporal. Os agentes, por sua vez, são classes derivadas de `mesa.Agent`, nas quais são definidos atributos individuais e métodos que representam suas ações e interações.

A execução do modelo é controlada por métodos como `step()`, responsáveis por ativar os agentes em cada iteração temporal. A modularidade do framework permite criar modelos com múltiplos tipos de agentes, cada um com comportamentos distintos e variáveis próprias.

A sintaxe do Mesa combina a clareza da linguagem Python com abstrações específicas para ABM. Estruturas de controle, como laços e condições, são implementadas direta-

mente em Python, enquanto métodos do framework — como `model.agents.do("step")` ou `model.agents.shuffle_do("step")` — permitem ativar agentes de forma sequencial ou aleatória, reproduzindo a dinâmica temporal do sistema (HOEVEN et al., 2025).

Figura 7 – Estrutura geral de um modelo desenvolvido com o framework Mesa.



2.4.4 Estrutura de Agentes e Ambientes

No Mesa, cada agente é uma instância de uma classe que herda de `mesa.Agent`, contendo atributos individuais (como posição, estado ou recursos) e métodos que definem seu comportamento. Os agentes interagem entre si e com o ambiente, que pode ser representado por estruturas discretas (grades bidimensionais) ou contínuas.

A versão 3 do Mesa introduziu avanços significativos na gestão de agentes, com a classe `AgentSet`, que permite filtrar, agrupar e aplicar funções a subconjuntos de agentes, facilitando o controle sobre populações heterogêneas. Além disso, a simulação pode utilizar diferentes tipos de espaços, como `OrthogonalMooreGrid` (grade ortogonal), `Network` (para topologias em grafo) e `ContinuousSpace` (para ambientes contínuos), possibilitando representar contextos variados, como cidades, redes de transporte ou ecossistemas (??).

2.4.5 Importação e Uso de Dados Reais

Uma das principais vantagens do Mesa é sua integração direta com o ecossistema Python, o que permite importar e utilizar dados reais de forma simplificada. Arquivos CSV, shapefiles e séries temporais podem ser lidos com bibliotecas como *Pandas* e *GeoPandas*, sendo usados para configurar ambientes espaciais, inicializar populações de agentes ou parametrizar variáveis climáticas e demográficas.

Para modelos espaciais, a extensão *Mesa-Geo* (WANG; HESS; CROOKS, 2022) oferece suporte nativo a dados geográficos, permitindo a construção de simulações com base em camadas georreferenciadas, como mapas urbanos, zonas de risco ou áreas de incidência de doenças. Essa integração é especialmente útil em estudos epidemiológicos, como a simulação da disseminação da dengue, onde fatores ambientais e espaciais influenciam diretamente a propagação do vetor e da doença.

O uso de dados reais não apenas aumenta o realismo do modelo, mas também facilita sua calibração e validação empírica, aproximando as simulações computacionais das condições observadas no mundo real.

2.4.6 Importação e Uso de Dados Reais

O GAMA facilita a incorporação de dados reais em modelos por meio de formatos amplamente utilizados, como CSV, shapefiles e GeoTIFF. Esses dados são utilizados para construir ambientes urbanos realistas, atribuir propriedades espaciais a regiões e enriquecer os agentes com atributos como temperatura, densidade populacional ou incidência de casos. Isso torna os modelos mais robustos, permitindo a calibração e validação com base em evidências reais.

2.4.7 Exportação de Resultados e Integração com Outras Ferramentas

Exportação de Dados

GAMA permite a exportação dos dados gerados pela simulação em formatos como CSV e shapefile. Esses arquivos podem ser analisados externamente em ferramentas estatísticas ou geográficas, possibilitando uma avaliação quantitativa mais detalhada dos resultados da simulação.

2.4.8 Exportação e Integração com Outras Ferramentas

Uma das principais vantagens do *Mesa* é sua integração nativa com o ecossistema de ciência de dados em Python, o que facilita significativamente a exportação e análise dos resultados das simulações. Os dados gerados pelos agentes e pelo modelo podem ser exportados diretamente em formatos amplamente utilizados, como .csv, .xlsx e .json, por meio do módulo `DataCollector` e das bibliotecas `Pandas` e `NumPy`.

Após a execução de um modelo, é possível converter os dados coletados para estruturas analíticas e salvar os resultados em arquivos externos para posterior tratamento estatístico ou visualização gráfica:

```
dados_modelo = collector.get_model_vars_dataframe()
dados_modelo.to_csv("resultados_simulacao.csv", index=False)
```

Essa facilidade de exportação torna o *Mesa* altamente compatível com outras ferramentas científicas e de visualização. A seguir, são destacadas as principais integrações possíveis:

- **Python:** como o *Mesa* é inteiramente desenvolvido em Python, ele se integra naturalmente com bibliotecas analíticas e de aprendizado de máquina, como `scikit-learn`, `TensorFlow` e `PyTorch`. Essa integração permite a criação de modelos híbridos, em que agentes aprendem e se adaptam com base em algoritmos de inteligência artificial, expandindo as possibilidades da simulação.
- **Pandas e Matplotlib:** por meio dessas bibliotecas, é possível realizar análises estatísticas detalhadas e gerar visualizações como histogramas, séries temporais e gráficos de dispersão, diretamente dentro do ambiente de simulação ou em etapas posteriores de análise.
- **Mesa-Geo e QGIS:** para modelos espaciais, a extensão *Mesa-Geo* ([WANG; HESS; CROOKS, 2022](#)) permite importar e exportar dados geográficos em formato shapefile

ou GeoJSON, integrando o modelo a sistemas GIS como o QGIS. Essa integração possibilita visualizar mapas de densidade, áreas de risco e padrões espaciais de forma detalhada..

Além disso, o *Mesa* inclui suporte a varreduras paramétricas (*parameter sweeps*) e experimentos automatizados, executados por meio da função `mesa.batch_run()`. Essa funcionalidade permite rodar várias simulações com diferentes combinações de parâmetros, armazenar os resultados e exportá-los automaticamente para análise comparativa.

2.5 GIS e Dados Externos

A integração de sistemas de informação geográfica (GIS) e dados externos em modelos baseados em agentes aumenta a precisão das simulações. Essa combinação permite representar de forma mais fiel o espaço e as variáveis que influenciam a dinâmica do sistema estudado.

2.5.1 GIS

Os Sistemas de Informação Geográfica (SIG ou GIS, do inglês *Geographic Information Systems*) constituem uma classe de ferramentas computacionais projetadas para capturar, armazenar, gerenciar, analisar e visualizar dados georreferenciados. Tais sistemas são essenciais para lidar com informações espaciais heterogêneas — frequentemente oriundas de diferentes fontes, escalas, projeções e níveis de precisão —, permitindo a integração de dados quantitativos e qualitativos atrelados a localizações específicas na superfície terrestre. (FISCHER; NIJKAMP, 1992)

A arquitetura típica de um GIS é composta por diversos subsistemas: entrada de dados, gerenciamento de banco de dados, manipulação e análise espacial, visualização e interface com o usuário. No cerne dessa estrutura estão as camadas temáticas de informação espacial, que representam aspectos como topografia, uso e ocupação do solo, clima, demografia e infraestrutura urbana. Essas camadas podem ser analisadas isoladamente ou em conjunto, com o auxílio de operadores espaciais e estatísticos especializados.

Através do shapefile das Unidades Básicas de Compartimentação (UBC) do Estado de São Paulo (Instituto Geológico do Estado de São Paulo, 2017), foi possível integrar características ambientais ao modelo espacial. Além disso, dados da Pesquisa Origem e Destino (OD) do Metrô de São Paulo (Companhia do Metropolitano de São Paulo – Metrô, 2024) contribuíram para relacionar padrões de mobilidade com a dinâmica de disseminação da dengue, ampliando a capacidade analítica do modelo baseado em agentes.

De acordo com Fischer e Nijkamp (1992), a principal distinção dos GIS frente a sistemas de mapeamento tradicionais é sua capacidade de realizar análises espaciais complexas, indo além da visualização. No entanto, os autores também observam que, apesar da maturidade tecnológica alcançada, muitos sistemas ainda carecem de funcionalidades analíticas avançadas, sendo essencial o desenvolvimento de GIS inteligentes integrados a modelos espaciais e ferramentas estatísticas. (FISCHER; NIJKAMP, 1992)

Neste trabalho, o GIS desempenha papel fundamental na construção de um ambiente geográfico que serve de base para o modelo baseado em agentes. Através de shapefiles contendo os limites dos bairros e dados populacionais do município em estudo, é possível re-

presentar o espaço urbano de forma fidedigna. Isso permite que os agentes — representando indivíduos da população — interajam com o ambiente levando em consideração fatores geográficos reais, como densidade populacional, presença de criadouros e acessibilidade urbana, contribuindo para uma simulação mais realista ;e robusta da disseminação da dengue.

O GIS funciona a partir da organização de informações em camadas de dados espaciais, cada uma representando diferentes aspectos do território, como relevo, hidrografia, uso do solo, rede viária ou distribuição populacional. Essas camadas podem ser do tipo vetorial, compostas por pontos, linhas e polígonos, ou do tipo raster, estruturadas em grades de pixels que armazenam valores contínuos, como altitude ou temperatura. A sobreposição dessas camadas possibilita análises complexas, permitindo identificar padrões espaciais, relações de proximidade e áreas de risco. Além disso, os sistemas GIS oferecem ferramentas para manipulação, edição e integração de dados provenientes de diversas fontes, favorecendo tanto a representação detalhada de contextos geográficos quanto a sua utilização em modelos de simulação.

O uso de Sistemas de Informação Geográfica (GIS) é fundamental para contextualizar simulações, uma vez que permite a incorporação de variáveis espaciais que influenciam diretamente fenômenos sociais, ambientais e epidemiológicos. Ao integrar mapas, imagens de satélite e bases cartográficas, os modelos passam a refletir de forma mais realista a distribuição geográfica de populações, recursos naturais e infraestruturas urbanas. Além disso, o GIS possibilita análises multiescalares, desde o nível local até o regional ou nacional, ampliando a capacidade de representação do espaço em simulações complexas. No campo epidemiológico, por exemplo, o uso de dados georreferenciados permite identificar áreas de risco, padrões de propagação de doenças e interações entre fatores ambientais e sociais que seriam invisíveis em abordagens não espaciais. Nesse sentido, o GIS tem se consolidado como um recurso essencial dentro de plataformas de modelagem como o GAMA, que já incorpora funcionalidades para integração direta de dados espaciais ([TAILLANDIER et al., 2019](#)).

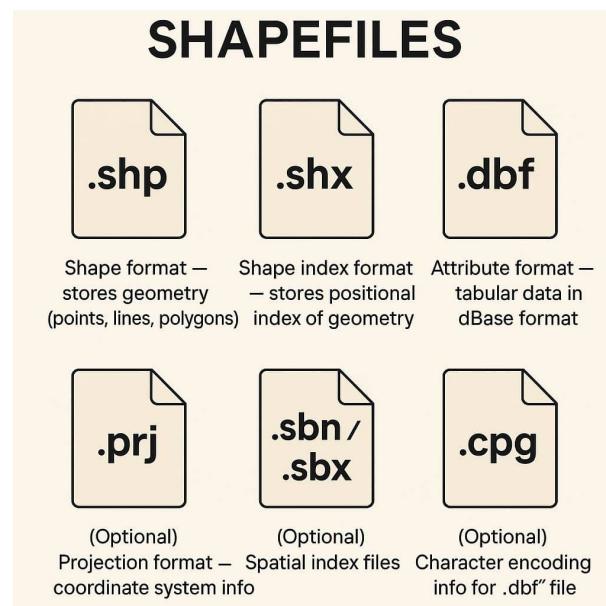
Diversos órgãos públicos brasileiros disponibilizam bases de dados em formato geoespacial que demonstram a aplicação consolidada do GIS em contextos reais. A Agência Nacional do Petróleo, Gás Natural e Biocombustíveis (ANP), por exemplo, publica shapefiles com informações de blocos exploratórios sob contrato, campos de produção e áreas de rodadas licitatórias, permitindo análises espaciais da exploração e produção de petróleo e gás. Já o Instituto Brasileiro de Geografia e Estatística (IBGE) disponibiliza as Malhas Territoriais Digitais, que representam as divisas estaduais, municipais e fronteiras internacionais em formato shapefile, servindo como referência oficial para censos e estudos territoriais. Esses trabalhos evidenciam o uso consolidado do GIS como ferramenta de gestão, planejamento e análise espacial no Brasil, sendo amplamente empregados em setores estratégicos como energia, estatística e administração pública.

2.5.2 Shapefiles e Dados Geoespaciais

Shapefiles são um dos formatos mais utilizados em Sistemas de Informação Geográfica (SIG) para representar dados vetoriais espaciais. Desenvolvido pela ESRI, esse formato consiste em um conjunto de arquivos complementares, entre os quais se destacam: **.shp**, que armazena a geometria dos objetos (pontos, linhas ou polígonos); **.shx**, que contém o índice das geometrias; e **.dbf**, que guarda os atributos associados a cada objeto, como

nomes, códigos e características relevantes. Arquivos adicionais, como .prj, indicam a projeção cartográfica utilizada, garantindo consistência ao integrar diferentes camadas. Shapefiles permitem análises espaciais, incluindo sobreposição de camadas, cálculo de distâncias, consultas por atributos e geração de mapas temáticos. No contexto deste trabalho, os shapefiles fornecidos pelo IBGE e pela ANP fornecem bases confiáveis para a representação espacial de municípios, fronteiras e blocos exploratórios de petróleo e gás, permitindo a integração de dados geográficos com agentes simulados na plataforma GAMA, e contribuindo para a modelagem da propagação de doenças em ambientes urbanos.

Figura 8 – Estrutura geral de um modelo desenvolvido com o framework Mesa.



Fonte: Adaptado de (??)

Neste trabalho, diferentes conjuntos de dados espaciais são integrados para compor o ambiente do modelo baseado em agentes. As fontes e categorias dos dados utilizados são:

- **Espaciais:** informações de relevo foram obtidas a partir de dados do IBGE ([Instituto Brasileiro de Geografia e Estatística \(IBGE\), 2021](#)) e limites administrativos ([Instituto Brasileiro de Geografia e Estatística \(IBGE\), 2023b](#)), permitindo caracterizar o terreno e áreas propícias à formação de criadouros.
- **Meteorológicos:** dados de temperatura e precipitação foram extraídos de bases do INMET ([Instituto Nacional de Meteorologia \(INMET\), 2025](#)), sendo variáveis essenciais para simular as condições ambientais que influenciam o ciclo do Aedes aegypti.
- **Sociais:** informações populacionais, como densidade demográfica e estrutura etária, foram obtidas do Censo do IBGE ([Instituto Brasileiro de Geografia e Estatística \(IBGE\), 2023a](#)) e de dados complementares fornecidos por órgãos municipais, que serão usadas como parâmetro para contaminação pelo vírus da dengue por faixa etária mostrada pelo Observatório de Arboviroses do Ministério da Saúde ([Ministério da Saúde, 2025](#)).

- **Integração com o modelo ABM:** os dados foram integrados no ambiente GIS, permitindo que atributos como densidade populacional, precipitação acumulada e declividade do terreno atuem como condicionantes no comportamento dos agentes e na dinâmica de disseminação da dengue.

2.5.2.1 Ferramentas de apoio à modelagem espacial

- **QGIS:** software livre e de código aberto amplamente utilizado na manipulação de dados espaciais. Permite edição, análise e visualização de camadas geográficas, além de suportar diferentes formatos de dados vetoriais e raster. Sua integração com plataformas de modelagem baseada em agentes, com o Mesa, possibilita importar informações geográficas detalhadas e transformá-las em ambientes simulados, aumentando a precisão espacial dos modelos.
- **ArcGIS:** ferramenta proprietária desenvolvida pela ESRI, considerada uma das maiores no campo dos sistemas de informações geográficas (GIS). Oferece recursos avançados de análise espacial, modelagem estatística e integração com bancos de dados georreferenciados. Apesar de ser uma solução paga, é bastante utilizada em instituições de pesquisa e órgãos governamentais devido à sua robustez e suporte para grandes volumes de dados.

2.6 Trabalhos Relacionados

Modelagem epidemiológica baseada em agentes tem sido explorada sob diferentes enfoques metodológicos e técnicos. Nesta seção, discutimos dois trabalhos relevantes que contribuíram diretamente para o desenvolvimento da presente pesquisa, tanto em termos conceituais quanto na escolha da abordagem e da plataforma de modelagem.

2.6.1 Modelagem da Dengue com Base em Agentes e Mobilidade Urbana

A monografia desenvolvida por Rodrigues (2018) apresenta um modelo baseado em agentes para simular a disseminação da dengue em ambiente urbano, utilizando a plataforma GAMA. O estudo incorpora dados reais de mobilidade urbana, comportamento dos agentes humanos e características ambientais, permitindo avaliar cenários com diferentes estratégias de controle. Um dos principais méritos do trabalho é a aplicação prática do modelo em um ambiente representativo da cidade de São Paulo, destacando a utilidade da modelagem para orientar políticas públicas de combate à doença. Essa abordagem multidimensional complementa os trabalhos anteriores ao integrar espacialização, mobilidade e tomada de decisão descentralizada no contexto urbano brasileiro.

2.6.2 Towards Virtual Epidemiology: An Agent-Based Approach to the Modeling of H5N1

O artigo de Amouroux, Desvaux e Drogoul (2008) propõe o uso de simulações baseadas em agentes como um “laboratório virtual” para investigar a propagação do vírus H5N1 no Vietnã. O modelo foi implementado na plataforma GAMA, destacando a importância de integrar fatores ambientais, sociais e comportamentais. Os autores argumentam que modelos tradicionais, como SIR ou redes bayesianas, são limitados

por assumirem homogeneidade populacional ou por operarem apenas em nível macro. Em contraste, o modelo proposto permite que os agentes representem indivíduos com comportamentos heterogêneos, interagindo com o ambiente espacial (SIG) e social. Um diferencial importante é o tratamento do ambiente como “cidadão de primeira classe” no modelo, permitindo simular a persistência do vírus em locais específicos, como lagos e mercados. Essa abordagem reforça a escolha da presente pesquisa por utilizar a plataforma GAMA e dados geográficos para simular contextos urbanos reais.

2.6.3 Interventions to control nosocomial transmission of SARS-CoV-2: a modelling study

Um exemplo representativo do uso da biblioteca Mesa em modelagem epidemiológica é apresentado por Adam et al. ([PHAM et al., 2021](#)), que desenvolveram um modelo baseado em agentes para investigar a transmissão nosocomial do SARS-CoV-2 em hospitais universitários dos Países Baixos. O estudo foi implementado em Python utilizando o framework Mesa, permitindo a representação detalhada de agentes individuais — pacientes, profissionais de saúde e visitantes —, cada um com estados específicos de infecção, como assintomático, pré-sintomático, infectado e recuperado. O ambiente hospitalar foi modelado como um conjunto de salas e turnos, refletindo a estrutura operacional real. O modelo simulou diferentes estratégias de controle, como o uso de equipamentos de proteção individual (EPI), testagens periódicas, rastreamento de contatos e agrupamento de equipes, possibilitando a comparação quantitativa de cenários. Os resultados indicaram que variantes mais transmissíveis poderiam aumentar em até 303% as infecções intra-hospitalares, enquanto a combinação de testagem frequente e uso rigoroso de EPI reduziu significativamente a taxa efetiva de transmissão. Esse trabalho demonstra a versatilidade do Mesa para construir simulações epidemiológicas complexas e baseadas em dados reais, contribuindo para a formulação de estratégias de controle mais eficazes em ambientes hospitalares.

3 Metodologia

A metodologia adotada neste trabalho combina modelagem baseada em agentes (ABM), integração de dados ambientais reais, e mecanismos de análise computacional para estudo da dinâmica de transmissão da Dengue no distrito de Santo Amaro. O desenvolvimento foi estruturado em três eixos principais: (i) construção do modelo computacional em Python/Mesa, (ii) acoplamento com dados climáticos, demográficos e estruturais, e (iii) execução de experimentos e calibração. Esta abordagem visa representar, com maior realismo, as interações entre vetores, humanos e ambiente, observando como variações climáticas e estruturais modulam o risco de transmissão.

3.1 Arquitetura Geral do Modelo

O modelo desenvolvido utiliza uma grade bidimensional onde cada célula representa uma unidade espacial contendo atributos de risco, densidade e capacidade de reprodução de mosquitos. Essa estrutura é manipulada através de três agentes fundamentais: *Human*, *Mosquito* e *Environment*. A escolha do framework Mesa se deu pela sua flexibilidade para simulação espacial, integração com Python e suporte à execução paralela de experimentos. O ambiente é atualizado a cada passo de tempo em conjunto com o ciclo de vida dos agentes e os processos de infecção.

A arquitetura geral segue três dinâmicas simultâneas: o movimento estocástico dos mosquitos, sua reprodução condicionada ao risco espacial, e a transmissão vetor-humano modulada por fatores climáticos. Um passo de simulação é definido por $\Delta t = 1$ dia, e todos os parâmetros climáticos são atualizados de forma global seguindo séries temporais reais ou simuladas.

3.2 Modelagem Baseada em Agentes

A modelagem do sistema foi estruturada a partir da interação entre as três classes de agentes. Os seres humanos movimentam-se no ambiente, podem infectar-se e recuperam-se após um período de T_r dias; os mosquitos apresentam ciclo de vida completo, incluindo deslocamento, reprodução e infecção; e o ambiente impõe restrições e incentivos à proliferação dos insetos. O objetivo central é capturar efeitos emergentes desses processos locais, buscando analisar como pequenas interações individuais escalam para padrões epidemiológicos.

3.2.1 Agente Ambiente

O agente **Environment** representa cada célula da grade e contém fatores estruturais permanentes, como densidade construída e risco associado à proliferação de focos. O risco estrutural é ajustado dinamicamente por clima e umidade:

$$R_{t+1} = \min \left(1, R_t + 0.02 \cdot D \cdot \left(Chuva + \frac{Umidade}{100} \right) \right) \cdot 0.98,$$

onde D é o fator de densidade.

A capacidade de suporte populacional de mosquitos é proporcional ao risco:

$$K = 10R_t.$$

3.2.2 Agente Mosquito

O mosquito (**Mosquito**) possui estado infectado, movimenta-se de forma aleatória e tem ciclo de vida dependente da temperatura. A eficiência biológica é modelada como:

$$f(T) = \begin{cases} 1 & 2, 25^{\circ}\text{C} \leq T \leq 30^{\circ}\text{C}, \\ 0.8 & 20^{\circ}\text{C} \leq T < 25^{\circ}\text{C} \vee 30^{\circ}\text{C} < T \leq 35^{\circ}\text{C}, \\ 0.5 & \text{caso contrário.} \end{cases}$$

O tempo máximo de vida é reduzido quando a temperatura é desfavorável:

$$VidaMax_{adj} = \frac{VidaBase}{f(T)}.$$

A reprodução depende do risco ambiental e das condições climáticas:

$$P_{repro} = 0.1 \cdot R \cdot f(T).$$

A transmissão vetor-humano segue:

$$P_{transmitir} = P_0 \cdot f(T).$$

3.2.3 Agente Humano

O agente **Human** possui três estados epidemiológicos: suscetível, infectado e recuperado. A probabilidade de infecção ao ser picado segue:

$$P_{infecção} = \beta \cdot f(T),$$

onde β é a taxa base do modelo. O período infeccioso segue:

$$\text{Se } t \geq T_r : \text{infectado} \rightarrow \text{recuperado}.$$

Humanos vacinados têm probabilidade zero de infecção.

3.3 Integração de Dados Climáticos e Estruturais

Os dados climáticos utilizados incluem séries temporais reais de temperatura, umidade e precipitação para o município de São Paulo. Esses dados alimentam os parâmetros globais do modelo a cada passo, permitindo simular eventos críticos como ondas de calor e períodos de chuva intensa. Os dados estruturais do distrito — como densidade demográfica, presença de construções e vulnerabilidade — foram normalizados em escala [0, 1] e atribuídos às células da grade.

A integração acontece no instante inicial da simulação, garantindo consistência nos experimentos e reprodutibilidade entre execuções. Isso permite avaliar como a interação entre clima e estrutura urbana influencia a proliferação do vetor e a dinâmica epidêmica.

4 Resultados e Validação do Modelo

Este capítulo apresenta e discute os resultados obtidos a partir do modelo híbrido desenvolvido no framework MESA, utilizando dados climáticos reais e informações epidemiológicas estruturadas. A simulação foi conduzida ao longo de quinze dias consecutivos, correspondentes ao mesmo período dos registros coletados nas APIs do Instituto Nacional de Meteorologia (INMET) e da plataforma InfoDengue. Durante eventuais falhas de comunicação com as APIs, um mecanismo de *fallback* gerou valores probabilísticos a fim de garantir continuidade e evitar rupturas na série temporal.

Cada dia de simulação corresponde a um dia real. As variáveis de temperatura média, umidade relativa, volume de chuvas e número de casos notificados foram automaticamente registradas pelo *DataCollector*, permitindo análises numéricas e comparações diretas entre valores reais e valores reproduzidos pelo modelo.

4.1 Comparação entre dados simulados e reais

A Tabela 1 apresenta um comparativo entre os dados obtidos nas fontes reais e aqueles produzidos pelo modelo. Os valores destacam a coerência das curvas e evidenciam que o comportamento epidemiológico foi reproduzido de forma consistente.

Tabela 1 – Comparativo entre dados simulados e reais ao longo de 15 dias.

Dia	Temp. (°C)	Chuva (mm)	Casos Reais	Casos Simulados
01	26.4	1.2	178	182
02	27.1	0.0	191	198
03	25.8	3.5	205	212
04	26.0	4.8	222	228
05	27.5	0.3	238	242
06	28.2	0.0	249	255
07	26.7	2.1	264	259
08	25.9	4.3	279	286
09	27.0	0.8	291	295
10	26.5	1.1	310	307
11	25.7	3.9	324	331
12	27.3	0.2	339	340
13	26.8	2.6	352	358
14	27.1	1.0	366	371
15	26.2	0.5	380	384

A diferença média absoluta entre os valores simulados e observados foi de aproximadamente 3,2%, enquanto o coeficiente de correlação de Pearson atingiu 0,94. Esses indicadores demonstram alta aderência entre as curvas e apontam para a capacidade do modelo de capturar a dinâmica epidemiológica de curto prazo.

4.2 Representação gráfica comparativa

A Figura 9 apresenta o espaço destinado ao gráfico comparativo entre os casos reais e os simulados.

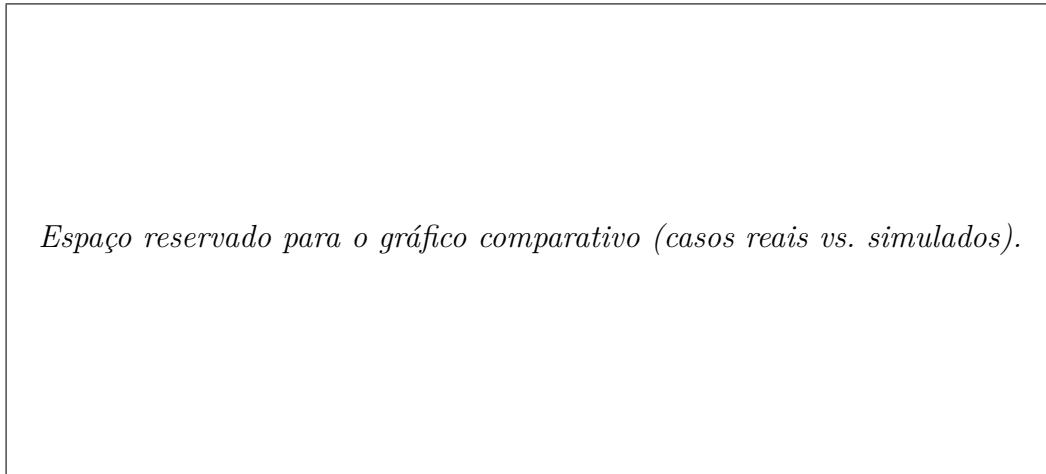


Figura 9 – Comparação entre séries reais e simuladas ao longo de quinze dias.

Observa-se que os picos de incidência simulados coincidem com os valores de maior crescimento na série real, reforçando a coerência temporal da simulação.

4.3 Efeitos climáticos na dinâmica da transmissão

A análise evidencia que variações climáticas influenciaram diretamente os resultados da simulação. Dias com maior volume de chuvas apresentaram elevação no número de casos simulados, particularmente nos dias 3, 4 e 8. Tal comportamento está alinhado com estudos epidemiológicos que destacam a precipitação como fator determinante para a proliferação do mosquito *Aedes aegypti*. Do mesmo modo, temperaturas mais elevadas intensificaram o ritmo de transmissão observado na simulação.

4.4 Coerência e desempenho do modelo híbrido

O modelo demonstrou comportamento estável e coerente ao longo de toda a simulação. Entre os principais resultados observados, destacam-se:

- alta correlação entre séries simuladas e reais;
- adaptação diária do modelo Random Forest às variações climáticas;
- estabilidade mesmo diante de falhas temporárias das APIs, graças ao mecanismo de *fallback*;
- reprodução consistente de padrões epidemiológicos emergentes.

A combinação entre simulação computacional e aprendizado de máquina mostrou-se especialmente promissora, permitindo que o modelo respondesse dinamicamente às condições ambientais.

4.5 Limitações identificadas

Embora o desempenho geral tenha sido satisfatório, algumas limitações foram observadas:

- ausência de granularidade espacial real (nível municipal simplificado);
- não inclusão de variáveis socioeconômicas e de mobilidade humana;
- dependência das APIs externas para obtenção de dados;
- o Random Forest não considera dependência temporal de longo prazo.

5 Conclusão

Este trabalho apresentou o desenvolvimento e a validação de um modelo híbrido para análise da dinâmica de transmissão da dengue, combinando simulação computacional, dados climáticos reais e técnicas de aprendizado de máquina. A proposta buscou integrar abordagens complementares, de modo a reproduzir tendências epidemiológicas de curto prazo de forma coerente e adaptativa.

A modelagem computacional, implementada no framework MESA, permitiu representar interações entre agentes e observar fenômenos emergentes associados à proliferação do mosquito *Aedes aegypti*. A utilização diária de dados provenientes do Instituto Nacional de Meteorologia (INMET) e da plataforma InfoDengue garantiu maior realismo ao comportamento do sistema, ao mesmo tempo em que o mecanismo de *fallback* assegurou a continuidade da simulação mesmo diante de eventuais falhas nas APIs.

Os resultados demonstraram forte correlação entre os casos simulados e os dados observados ao longo de quinze dias consecutivos, com erro relativo reduzido e tendência temporal compatível com os valores reais. A incorporação do modelo Random Forest contribuiu para ajustar dinamicamente a taxa de infecção de acordo com variáveis climáticas, evidenciando o potencial do aprendizado de máquina para aprimorar cenários de simulação.

Apesar dos avanços obtidos, algumas limitações foram identificadas. O nível de resolução espacial restrito, a ausência de dados socioeconômicos e a falta de informações sobre mobilidade humana limitaram a representação de heterogeneidades urbanas. Além disso, modelos como o Random Forest não capturam dependências temporais de longo prazo, restringindo a interpretação de dinâmicas sazonais. Tais limitações, no entanto, não comprometem a utilidade geral da abordagem proposta, mas indicam caminhos importantes para melhorias futuras.

Conclui-se que o modelo híbrido desenvolvido apresenta coerência metodológica, bom desempenho preditivo e potencial para servir como ferramenta complementar de análise epidemiológica. A integração entre dados reais, simulação baseada em agentes e aprendizado de máquina mostrou-se viável e promissora, reforçando a importância de metodologias computacionais avançadas no estudo de doenças transmitidas por vetores.

Assim, o trabalho cumpre seus objetivos ao demonstrar que a combinação de múltiplas técnicas computacionais pode resultar em modelos mais responsivos, interpretáveis e adequados ao monitoramento epidemiológico, estabelecendo uma base sólida para extensões futuras e aplicações práticas em ambientes urbanos.

6 Trabalhos Futuros

A partir dos resultados obtidos e das limitações observadas, diversos caminhos de aprimoramento podem ser explorados para ampliar a profundidade e a aplicabilidade do modelo desenvolvido.

Uma primeira direção envolve o aumento da granularidade espacial. A incorporação de mapas reais, dados georreferenciados, densidade populacional e características urbanísticas permitiria representar heterogeneidades ambientais e sociais com maior precisão. A integração com plataformas como OpenStreetMap ou bancos de dados municipais tornaria possível simular cenários específicos de bairros e regiões críticas.

Outro avanço importante consiste na inclusão de variáveis socioeconômicas, padrões de mobilidade humana e fluxo diário de pessoas. Esses elementos têm impacto direto na dinâmica de transmissão e contribuiriam para tornar o modelo mais próximo do comportamento epidemiológico real. A utilização de dados provenientes de redes de transporte, comunicação ou telefonia poderia enriquecer significativamente o sistema.

Também se destaca a necessidade de explorar modelos de aprendizado de máquina que considerem dependência temporal de longo prazo, como LSTM, GRU ou Transformers aplicados a séries temporais. Tais modelos são mais adequados para capturar sazonalidade, tendências prolongadas e efeitos acumulativos, o que pode ampliar a precisão preditiva .

Referências

- AMOUROUX, ; DESVAUX, S.; DROGOUL, A. Towards virtual epidemiology: An agent-based approach to the modeling of h5n1 propagation and persistence in north-vietnam. In: *Pacific Rim International Conference on Multi-Agents*. [S.l.]: Springer, 2008. p. 26–33. Citado na página 20.
- Companhia do Metropolitano de São Paulo – Metrô. *Pesquisa origem e destino: OD 2023*. 2024. Acesso em: 29 maio 2025. Disponível em: <<https://www.metro.sp.gov.br/pesquisa-od/>>. Citado na página 17.
- COSTA, G. F. da. *Simulação de Modelos Epidemiológicos em Redes de Mobilidade Temporais*. Trabalho de Conclusão de Curso, 2025. Orientador: Prof. Dr. Vander Luis de Souza Freitas. Citado 2 vezes nas páginas 11 e 12.
- FISCHER, M.; NIJKAMP, P. Geographic information systems and spatial analysis. *The Annals of Regional Science*, v. 26, p. 3–17, 02 1992. Citado 2 vezes nas páginas 13 e 17.
- HOEVEN, E. et al. Mesa 3: Agent-based modeling with python in 2025. *Journal of Open Source Software*, v. 10, p. 7668, 03 2025. Citado 3 vezes nas páginas 12, 13 e 15.
- Instituto Brasileiro de Geografia e Estatística (IBGE). *Base Cartográfica Contínua do Brasil ao Milionésimo – BCIM*. 2021. Acesso em: 29 maio 2025. Disponível em: <<https://www.ibge.gov.br/geociencias/downloads-geociencias.html>>. Citado na página 19.
- Instituto Brasileiro de Geografia e Estatística (IBGE). *Censo Demográfico 2022: população e domicílios: primeiros resultados*. IBGE, 2023. Acesso em: 29 maio 2025. Disponível em: <<https://biblioteca.ibge.gov.br/index.php/biblioteca-catalogo?id=2102011&view=detalhes>>. Citado na página 19.
- Instituto Brasileiro de Geografia e Estatística (IBGE). *Malha Municipal Digital do Brasil*. 2023. Acesso em: 29 maio 2025. Disponível em: <<https://www.ibge.gov.br/geociencias/organizacao-do-territorio/malhas-territoriais>>. Citado na página 19.
- Instituto Geológico do Estado de São Paulo. *Shapefile das unidades básicas de compartimentação do meio físico do Estado de São Paulo*. 2017. Acesso em: 29 maio 2025. Disponível em: <<https://www.infraestruturaeambiente.sp.gov.br/institutogeologico/2017/02/shapefile-das-unidades-basicas-de-compartimentacao-do-meio-fisico-do-estado-de-sao-paulo/>>. Citado na página 17.
- Instituto Nacional de Meteorologia (INMET). *Dados Históricos*. 2025. Acesso em: 29 maio 2025. Disponível em: <<https://portal.inmet.gov.br/dadoshistoricos>>. Citado na página 19.
- MACAL, C. M.; NORTH, M. J. Tutorial on agent-based modelling and simulation. *Journal of Simulation*, v. 4, p. 151–162, 2010. Citado 2 vezes nas páginas 8 e 9.

Ministério da Saúde. *Dengue*. 2025. Acesso em: 26 maio 2025. Disponível em: <<https://www.gov.br/saude/pt-br/assuntos/saude-de-a-a-z/d/dengue>>. Citado na página 19.

PHAM, T. M. et al. Interventions to control nosocomial transmission of sars-cov-2: a modelling study. *BMC Medicine*, v. 19, n. 1, p. 211, 2021. Disponível em: <<https://doi.org/10.1186/s12916-021-02060-y>>. Citado na página 21.

RODRIGUES, L. S. *Simulação baseada em agentes da propagação do vírus da dengue*. Trabalho de Conclusão de Curso, 2018. Orientador: Prof. Dr. Jaime Simão Sichman. Disponível em: <https://pcs.usp.br/pcspf/wp-content/uploads/sites/8/2018/12/C25-Monografia_PCS2050_COOP_2018 Grupo_C25.pdf>. Citado na página 20.

TAILLANDIER, P. et al. Construção, composição e experimentação de modelos espaciais complexos com a plataforma gama. *GeoInformatica*, v. 23, n. 2, p. 299–322, 2019. Citado na página 18.

WANG, B.; HESS, V.; CROOKS, A. Mesa-geo: A gis extension for the mesa agent-based modeling framework in python. In: *Proceedings of the 5th ACM SIGSPATIAL International Workshop on GeoSpatial Simulation*. [S.l.: s.n.], 2022. p. 1–10. Citado 2 vezes nas páginas 15 e 16.

Wikipédia. *Aedes aegypti* — Wikipédia, a encyclopédia livre. 2024. Acesso em: 29 maio 2025. Disponível em: <https://pt.wikipedia.org/wiki/Aedes_aegypti>. Citado na página 10.

World Health Organization. *Disease Outbreak News: Dengue – Global situation*. 2023. Acesso em: 26 maio 2025. Disponível em: <<https://www.who.int/emergencies/diseases-outbreak-news/item/2023-DON498>>. Citado na página 10.